

AAAI 论文方法部分草稿：多尺度 Prompt 感知 Superpixel 组织分割

1 方法

1.1 问题定义

给定一张 HE 染色全视野病理切片或其 $10\times$ 尺度图像，记其图像域为 $\Omega \subset \mathbb{R}^2$ 。用户交互由一组正向提示与负向提示组成：

$$\mathcal{P}^+ = \{p_i^+\}_{i=1}^{N_+}, \quad \mathcal{P}^- = \{p_j^-\}_{j=1}^{N_-}, \quad (1)$$

其中每个提示可以是矩形框、局部区域或由提示区域映射得到的 superpixel 集合。对于目标组织类别 c ，本文将交互式组织分割建模为一次 target-vs-rest 二分类任务：

$$f_\theta(I, \mathcal{P}^+, \mathcal{P}^-, c) \rightarrow M_c, \quad (2)$$

其中 I 为 HE 图像， $M_c \in [0, 1]^{|\Omega|}$ 为目标类别 c 的概率掩膜。不同 query 之间的目标掩膜允许重叠，因为病理组织类别的交互式查询是以用户意图为中心定义的，而不是以一次全局互斥语义分割为中心定义的。

现有 PRET-superpixel 流程已经能够将 HE 图像转换为区域级 token 并进行 prompt retrieval，但其最终分割结果仍依赖固定尺度、手工阈值和经验式 score-to-mask 转换。为此，本文提出一个多尺度 prompt 感知 superpixel 组织分割框架，记为 CellAtlas-MPS。该框架保留 PRET-superpixel 中稳定的区域表示和 prompt retrieval 主干，同时引入三个可学习或可校准模块：Prompt Scale Selector、Prompt-conditioned Mask Decoder 和 Graph Refiner，从而将尺度选择、阈值校准和区域级掩膜生成统一到可验证的学习框架中。

1.2 总体框架

CellAtlas-MPS 由五个阶段组成。首先，HE 图像被划分为 small、medium 和 large 三种尺度的 superpixel，并为每个 superpixel 构建区域 token。其次，用户给定的正负 prompt 被映射到对应尺度的 superpixel 集合，并形成一次 prompt-task。第三，在每个尺度上执行 prompt retrieval，得到每个 superpixel 相对于目标 prompt 的正向分数、负向分数和综合分数。第四，Prompt Scale Selector 根据 prompt 几何、prompt 纯度和各尺度 score 分布自动选择合适尺度。最后，Prompt-conditioned Mask Decoder 或 Graph Refiner 将区域 token、prompt score 和邻接上下文转换为 superpixel 级目标概率，并投影回像素空间生成最终掩膜。

整体流程可表示为：

$$I \rightarrow \{\mathcal{G}^s\}_{s \in \mathcal{S}} \rightarrow \{Z^s, A^s\}_{s \in \mathcal{S}} \rightarrow \{R^s(q)\}_{s \in \mathcal{S}} \rightarrow \hat{s} \rightarrow \hat{M}_q, \quad (3)$$

其中 $\mathcal{S} = \{\text{small}, \text{medium}, \text{large}\}$ 表示尺度集合， $\mathcal{G}^s$ 表示尺度 s 下的 superpixel 图， Z^s 表示 region token 矩阵， A^s 表示 superpixel 邻接边， $R^s(q)$ 表示 query q 在尺度 s 下的 retrieval 响应， $\hat{s}$ 表示选择的尺度， $\hat{M}_q$ 表示最终预测掩膜。

1.3 数据组织与 Prompt-task 构建

本文使用统一 manifest 组织每张 WSI 的 HE 路径、10× 组织标注、细胞核类别图、细胞核实例图、细胞特征、细胞坐标、多边形文件、已有 superpixel 结果以及 prompt 文件。当前 v3 数据清单包含 20 张 HE 切片；每张切片均具有 HE 图像、GT 组织掩膜、细胞特征、细胞坐标、已有 medium 尺度 superpixel 及对应 token。已有高纯度 prompt 文件包含 1161 条 prompt 记录，覆盖 20 张切片，prompt 来源为基于 GT 纯度筛选的区域框。

每个训练或评估样本被定义为一次 prompt 分割任务：

$$q = (\text{image_id}, c, \mathcal{P}^+, \mathcal{P}^-), \quad (4)$$

其中 c 为目标组织类别。对于 prompt 区域 B ，其纯度定义为该区域内目标类别像素占有效组织像素的比例：

$$\rho(B, c) = \frac{\sum_{x \in B} \mathbb{I}[Y(x) = c]}{\sum_{x \in B} \mathbb{I}[Y(x) \neq \text{background}] + \epsilon}. \quad (5)$$

在已有 expert prompt 之外，我们进一步设计自动 prompt-task 生成策略，包括 clean positive、noisy positive 和 hard negative 三类样本。clean positive 要求 $\rho(B, c) \geq 0.8$ ；noisy positive 覆盖 $0.5 \leq \rho(B, c) < 0.8$ 的真实交互噪声；hard negative 不从随机背景中采样，而优先选择与目标类别在区域 token 空间中相似、但 GT 类别不同的区域，以模拟肿瘤上皮与正常腺体、坏死与黏液、肌层与浆膜下组织等易混淆情况。

1.4 多尺度 Superpixel 与 Region Token

为适应不同大小的用户提示和组织结构，本文为每张图像构建三种尺度的 superpixel：

$$d_{\text{small}} = 0.5d_0, \quad d_{\text{medium}} = d_0, \quad d_{\text{large}} = 2d_0, \quad (6)$$

其中 d_0 为当前 full10x auto-physical 流程确定的基础区域直径。medium 尺度直接复用已有 PRET-superpixel 结果，以保持与当前稳定主线一致；small 尺度通过对 medium 区域进行局部细分获得更细粒度边界；large 尺度通过对相邻 medium 区域进行空间聚合获得更大语义区域。对于需要独立验证尺度效应的实验，large 或全部尺度也可以由 SLIC 重新生成。

对每个图像 image_id 和尺度 s ，标准输出包括：

$$\{\text{he_10x_rgb}, \text{superpixels}, \text{superpixels.csv}, A^s, Z_{\text{base}}^s, Z_{\text{enh}}^s, \text{gt_label_stats}\}. \quad (7)$$

其中 $A^s \in \mathbb{N}^{E_s \times 2}$ 为无向邻接边列表，而不是稠密邻接矩阵。每个 superpixel 记录面积、中心点、边界框、细胞数量、细胞密度、GT majority label、目标类别比例、GT 纯度和有效组织比例。基础 token Z_{base}^s 使用 `image_cell_reg_cellw0p5`，当前维度为 274；增强 token Z_{enh}^s 在基础 token 上加入纹理和细胞统计特征，当前维度为 309，并作为特征消融项。

对于一个 superpixel v_k^s ，其基础表示写为：

$$z_k^s = \text{Norm}([\phi_{\text{img}}(v_k^s), \phi_{\text{cell}}(v_k^s), \phi_{\text{reg}}(v_k^s)]), \quad (8)$$

其中 ϕ_{img} 表示图像区域特征， ϕ_{cell} 表示区域内细胞特征聚合， ϕ_{reg} 表示配准后的细胞表达或形态相关特征， $\text{Norm}(\cdot)$ 表示向量归一化。增强表示进一步拼接纹理统计和细胞统计：

$$\tilde{z}_k^s = \text{Norm}([z_k^s, \phi_{\text{tex}}(v_k^s), \phi_{\text{stat}}(v_k^s)]). \quad (9)$$

1.5 Prompt Retrieval Baseline

在每个尺度 s 下, prompt 区域首先被映射为 superpixel 集合。令 $Q^{+,s}$ 和 $Q^{-,s}$ 分别表示正向和负向 prompt 对应的 token 集合。对于任意候选 superpixel token z_k^s , 其正向相似度和负向相似度定义为:

$$r_{k,+}^s = \max_{u \in Q^{+,s}} \cos(z_k^s, u), \quad r_{k,-}^s = \max_{u \in Q^{-,s}} \cos(z_k^s, u). \quad (10)$$

综合 retrieval 分数为:

$$r_k^s = \begin{cases} r_{k,+}^s - \lambda r_{k,-}^s, & |\mathcal{P}^-| > 0, \\ r_{k,+}^s, & |\mathcal{P}^-| = 0, \end{cases} \quad (11)$$

其中 λ 为负向 prompt 权重, 默认设置为 0.5。该 baseline 保留了当前 PRET-superpixel 的可解释性: 高分区域表示与正向 prompt 相似, 同时被负向 prompt 抑制。每个 query-scale 结果保存 segment id、正向分数、负向分数、综合分数、rank percentile、superpixel 级 GT soft label、hard label、面积和中心坐标, 用于后续尺度选择与 mask decoder 训练。

1.6 Prompt Scale Selector

固定使用 medium 尺度无法同时满足小范围精细 prompt 和大范围语义 prompt。本文设计 Prompt Scale Selector, 将尺度选择建模为三分类问题:

$$g_\psi(h_q) \rightarrow \hat{s} \in \{\text{small}, \text{medium}, \text{large}\}, \quad (12)$$

其中 h_q 为 query 级特征。该特征包含 prompt 面积、prompt 框宽高、长宽比、prompt 纯度、各尺度覆盖到的 prompt token 数量, 以及各尺度 retrieval score 的统计量, 例如标准差和正负 score gap。训练标签由三尺度 baseline 结果自动产生:

$$s^* = \arg \max_{s \in S} \text{Dice}_{\text{select}}^s(q), \quad (13)$$

其中 $\text{Dice}_{\text{select}}$ 可以取 BestDice、classwise top-area Dice 或 prompt-adaptive Dice。第一版实现优先采用 Random Forest、Gradient Boosting 或轻量 MLP, 而不是直接引入大型 Transformer, 以降低小样本 WSI 设置下的过拟合风险。

尺度选择模型采用 WSI-level 划分。对于 20 张切片, 使用 5-fold by image_id 协议, 使同一张 WSI 上的 prompt 不会同时出现在训练集和测试集。每个 fold 中, 训练、验证和测试图像按 16/2/2 划分。报告指标包括 scale accuracy、macro F1、chosen-scale Dice、oracle-scale Dice 以及 small-only、medium-only、large-only 和 manual prompt-size rule 的对照结果。

1.7 Prompt-conditioned Mask Decoder

Prompt retrieval 给出了区域排序, 但仍需要将 score 转换为可用于分割的概率。为替代手工阈值, 本文引入 Prompt-conditioned Mask Decoder, 对每个 query-scale-superpixel 输出目标概率:

$$p_k^s = \sigma(d_\omega(x_k^s; q)), \quad (14)$$

其中 $\sigma(\cdot)$ 为 Sigmoid 函数, d_ω 为 MLP decoder, x_k^s 为融合 prompt 响应、区域表示和几何上下文的节点特征:

$$x_k^s = [z_k^s, r_{k,+}^s, r_{k,-}^s, r_k^s, \text{rank}(r_k^s), a_k, \bar{x}_k, \bar{y}_k, n_k, \delta_k, d_k^+, d_k^-, \mu_{\mathcal{N}(k)}(r), \max_{\mathcal{N}(k)}(r), \sigma_{\mathcal{N}(k)}(r)], \quad (15)$$

其中 a_k 为区域面积, $(\bar{x}_k, \bar{y}_k)$ 为空间归一化中心坐标, n_k 为细胞数量, δ_k 为细胞密度, d_k^+ 和 d_k^- 分别为到正向和负向 prompt 的距离, $\mathcal{N}(k)$ 为邻接 superpixel 集合。监督标签使用 superpixel 内目标类别像素比例:

$$y_k^s = \frac{\sum_{x \in v_k^s} \mathbb{I}[Y(x) = c]}{\sum_{x \in v_k^s} \mathbb{I}[Y(x) \neq \text{background}] + \epsilon}, \quad \bar{y}_k^s = \mathbb{I}[y_k^s > 0.5]. \quad (16)$$

decoder 训练使用 BCE 与 Soft Dice 的组合损失:

$$\mathcal{L}_{\text{dec}} = \text{BCEWithLogits}(o, y; \alpha) + \lambda_{\text{dice}} \left(1 - \frac{2 \sum_k p_k y_k + \epsilon}{\sum_k p_k + \sum_k y_k + \epsilon} \right), \quad (17)$$

其中 o 为 logit, α 为类别不平衡时的正样本权重, λ_{dice} 默认设置为 1.0。

1.8 Graph Refiner

病理组织区域具有空间连续性, 单独对每个 superpixel 做 MLP 预测容易产生孤立假阳性或局部断裂。本文进一步将 superpixel 视为图节点, 将邻接关系 A^s 视为边, 构建 Graph Refiner:

$$\mathcal{H}^{(0)} = X^s, \quad \mathcal{H}^{(\ell+1)} = \text{GraphSAGE}_{\ell}(\mathcal{H}^{(\ell)}, A^s), \quad (18)$$

$$p_k^s = \sigma \left(W_o h_k^{(L)} + b_o \right). \quad (19)$$

GraphSAGE 被优先采用, 因为它在区域图上具有较好的稳定性, 并且不需要构造稠密邻接矩阵。Graph Refiner 与 MLP decoder 使用相同的 prompt-conditioned 节点特征和监督标签, 但通过邻域聚合显式引入局部上下文, 使模型能够在保留 prompt 响应的同时平滑组织边界并抑制空间上不一致的预测。

1.9 多尺度融合

尺度选择给出一个单尺度决策, 而多尺度融合进一步利用三个尺度的互补性。本文比较五类策略: medium-only baseline、manual prompt-size rule、learned scale selector、score-level fusion 和 oracle best scale。其中 oracle 只作为上限, 不参与实际部署。score-level fusion 将三个尺度的概率图投影到同一 $10 \times$ 空间后加权融合:

$$P(x) = w_{\text{small}} P_{\text{small}}(x) + w_{\text{medium}} P_{\text{medium}}(x) + w_{\text{large}} P_{\text{large}}(x), \quad \sum_{s \in \mathcal{S}} w_s = 1. \quad (20)$$

权重 w_s 可以由 scale selector 的类别概率给出, 也可以由轻量 MLP 根据 query 特征预测。作为无训练对照, max fusion 定义为:

$$P(x) = \max_{s \in \mathcal{S}} P_s(x). \quad (21)$$

1.10 训练与评估协议

所有可学习模块均采用 WSI-level 5-fold 评估, 避免同一切片内高度相关的 prompt 造成数据泄漏。训练集由自动 prompt-task 和训练 WSI 中的 expert prompt 共同构成; 测试时分别报告 automatic prompt setting 和 expert prompt setting。主要指标包括 Dice、mIoU、Boundary F1、Precision、Recall、PredArea 和 GTArea。对于 retrieval baseline, 额外报告 mAP、AUROC、P@top5、P@top10、不同阈值策略下的 Dice 以及 BestDice。对于尺度选择模块, 额外报告 scale accuracy、macro F1 和 chosen-scale Dice。

消融实验围绕三个问题设计。第一, 特征消融比较 image only、cell only、image+cell 以及 image+cell+texture/cellstats, 验证细胞级信息和纹理统计是否提升组织分割。第二, prompt 消融比较 1 positive、1 positive+1 negative、1 positive+3 negative、expert prompt、automatic prompt、clean prompt

和 noisy prompt, 分析交互质量对结果的影响。第三, 多尺度和模型消融比较 small-only、medium-only、large-only、manual scale rule、learned scale selector、MLP decoder、GraphSAGE refiner 和 multi-scale fusion, 验证本文各模块对最终分割性能的贡献。

1.11 实现与验证细节

当前实现将 v3 数据产品统一保存到 `/nfs-medical3/zyh/v3/cellatlas_pret_superpixel_aaai_v3_multiscale_refiner`。输入 manifest 已验证 20 张图像的 HE、GT、细胞特征、细胞坐标、已有 superpixel、基础 token、增强 token 和 prompt 路径均存在。多尺度 token 构建阶段已在 hierarchical 模式下完成 4 张图像的三尺度验证, 共 12 个 image-scale 输出; small、medium 和 large 的 segment 数量分别处于 2792–4591、888–1459 和 345–434 范围内, 基础 token 维度为 274, 增强 token 维度为 309。针对少数 GT 非背景区域未被 superpixel 覆盖的问题, 额外设计覆盖修复步骤: 仅对 $Y \neq \text{background}$ 且 `superpixels=-1` 的区域按尺度相关网格补充 segment, 并将新增 segment token 设为最近已有 segment 的 token, 从而避免将玻片空白强制纳入组织区域。